




PEMANFAATAN MACHINE LEARNING UNTUK IDENTIFIKASI FAKTOR PENDAPATAN

BY GROUP A

CARRISA PUTRI ARABELLA

FARICHA CAHYA METIA

FATIHATURROHMAH

ADITYA FEBRIO SETIAWAN

ANDHIKA PRADANA RAHMA DHANY



LATAR BELAKANG

Ketimpangan pendapatan di negara berkembang sering kali menghambat pencapaian target penurunan Gini Ratio (RPJMN). Hal ini diperparah oleh sistem pengumpulan data kependudukan secara manual yang memakan waktu lama dan biaya besar. Akibatnya, terjadi keterlambatan pasokan informasi yang menghambat akurasi dan kecepatan pemerintah dalam mengambil kebijakan strategis.

Sebagai solusi, teknologi machine learning diterapkan untuk melakukan **klasifikasi** biner pada tingkat pendapatan individu (**$\leq 50K$ vs $> 50K$ USD/tahun**). Proses ini memanfaatkan dataset **Adult Census Income** dari Kaggle berdasarkan fitur sosio-demografi seperti usia, tingkat pendidikan, dan jam kerja.


Perbandingan beberapa algoritma di dalam proyek ini berfokus penuh pada kebenaran proses pengolahan data. Melalui pencegahan kebocoran informasi dan penanganan class imbalance yang tepat, tujuan akhirnya adalah menghasilkan model prediksi pendapatan yang adil, objektif, serta bebas dari risiko overfitting.

RUMUSAN MASALAH


- 1 Variabel apa yang paling berpengaruh terhadap tingkat pendapatan individu?
- 2 Bagaimana mengolah data mentah (missing values & encoding) dengan benar tanpa memicu kebocoran informasi?
- 3 Bagaimana teknik feature engineering dan penanganan class imbalance diterapkan agar model tidak bias?
- 4 Algoritma klasifikasi mana yang memberikan performa terbaik dan paling stabil setelah hyperparameter tuning?

TUJUAN

- 1 Mengidentifikasi variabel yang paling dominan terhadap pendapatan melalui EDA.
- 2 Mengolah data mentah (missing values & encoding) tanpa kebocoran informasi.
- 3 Menerapkan feature engineering dan mengatasi class imbalance agar model adil.
- 4 Membandingkan performa tiga algoritma kemudian melakukan hyperparameter tuning.




DESKRIPSI DATASET





Adult Census Income Dataset merupakan dataset dari UCI Machine Learning Repository yang berasal dari data sensus penduduk Amerika Serikat tahun 1994 dan digunakan untuk memprediksi apakah pendapatan tahunan individu berada pada kategori $\leq 50K$ atau $> 50K$, sehingga termasuk dalam permasalahan klasifikasi biner (binary classification).

Atribut	Keterangan
Jumlah Baris	32.561 observasi
Jumlah Kolom	15 fitur (14 fitur input + 1 target variable)
Fitur Numerik	6 kolom
Fitur Kategorikal	8 kolom
Target Variable	income (binary: $\leq 50K$ atau $> 50K$)
Missing Value	workclass, occupation, native.country

EXPLORASI DATA ANALYSIS (EDA)




- Heatmap korelasi menunjukkan education.num memiliki korelasi positif tertinggi terhadap income ($\approx 0,34$).
- Variabel age, hours.per.week, dan capital.gain juga memiliki hubungan positif dengan income.



HMMM...

DATA PREPROCESSING

HMMM...



MISSING VALUE HANDLING

Ditemukan nilai '?' yang merepresentasikan data kosong pada:

- Workclass : 1.836
- Occupation : 1.843
- Native Country : 583

Penanganan:

- '?' → NaN
- Imputasi menggunakan modus

Kolom 'workclass' NaN diisi dengan modus: 'Private'.

Kolom 'occupation' NaN diisi dengan modus: 'Prof-specialty'.

Kolom 'native.country' NaN diisi dengan modus: 'United-States'.

STANDARISASI DATA

Menyamakan skala antar fitur numerik agar tidak ada variabel yang mendominasi proses pelatihan model.

- Seluruh fitur memiliki rata-rata (mean) mendekati 0
- Seluruh fitur memiliki standar deviasi (std) sebesar 1
- Data siap digunakan pada tahap pemodelan machine learning

DATA CLEANING

- Ditemukan 24 data duplikat
- Seluruh data duplikat dihapus

DETEKSI DAN PENANGANAN OUTLIER

Jumlah outlier yang ditemukan:

- age : 142 observasi
- fnlwgt : 993 observasi
- education.num : 1.193 observasi
- capital.gain : 2.712 observasi
- capital.loss : 1.519 observasi
- hours.per.week : 9.002 observasi

Keputusan Penanganan

- Outlier tidak dihapus dari dataset.
- Outlier dianggap masih merepresentasikan kondisi nyata pada data sensus.
- Penghapusan outlier berpotensi mengubah distribusi asli populasi.
- Penghapusan outlier juga dapat menyebabkan hilangnya informasi penting yang dibutuhkan dalam proses klasifikasi pendapatan.

FEATURE ENGINEERING & PENANGANAN KETIDAKSEIMBANGAN KELAS

FEATURE ENGINEERING


Pemisahan variabel:

- X (fitur prediktor)
- y (income)

Target:

- 0 = income $\leq$ 50K
- 1 = income $>$ 50K


Distribusi Kelas Income



CLASS IMBALANCE


- Sebelum SMOTE, distribusi kelas tidak seimbang (24.698 data Income $\leq$ 50K dan 7.839 data Income $>$ 50K).
- Setelah SMOTE, kedua kelas menjadi seimbang dengan masing-masing 24.698 observasi.

Distribusi Kelas income Setelah SMOTE



HOEK!

HOEK!!




METODE PEMODELAN MACHINE LEARNING

Logistik Regression

Model klasifikasi linear yang digunakan sebagai baseline model. Logistic Regression mudah diinterpretasikan dan mampu memprediksi probabilitas suatu kelas berdasarkan hubungan antar variabel.

Random Forest


Algoritma ensemble berbasis Decision Tree yang bekerja dengan menggabungkan banyak pohon keputusan. Model ini mampu menangkap pola non-linear dan lebih tahan terhadap overfitting.



TCH!!

XgBoost

Algoritma boosting yang membangun model secara bertahap untuk memperbaiki kesalahan prediksi sebelumnya. XGBoost dikenal memiliki akurasi tinggi dan menghasilkan performa terbaik pada penelitian ini.





Perbandingan Kinerja Model Klasifikasi




Model	Accuracy	Precision	Recall	F1-Score
Logistic Regression	0,7698	0,52	0,76	0,61
Random Forest	0,8364	0,65	0,70	0,67
XGBoost	0,8522	0,68	0,73	0,70

- XGBoost memiliki performa terbaik dengan accuracy 85,22%.
- Random Forest menunjukkan performa yang paling tinggi setelah XGBoost.
- Logistic Regression memiliki performa paling rendah sehingga digunakan sebagai model baseline.
- XGBoost dipilih untuk tahap hyperparameter tuning.

WAR~
IS OVER~



OPTIMASI HYPERPARAMETER MODEL XGBOOST



(PROSES TUNING)

(PARAMETER TERBAIK)

Metode Optimasi

- RandomizedSearchCV
- 50 kombinasi parameter
- 3-Fold Cross Validation
- Model: XGBoost

Parameter	Nilai Optimal
n_estimators	100
max_depth	5
learning_rate	0,1
subsample	0,7
colsample_bytree	0,9
gamma	0


(HASIL TUNING)

Metrik	Sebelum Tuning	Sesudah Tuning	Peningkatan
Accuracy	0,8522	0,8351	-0,0171
Recall kelas 1 (>50K)	0,7302	0,7851	+0,0549
F1-score kelas 1 (>50k)	0,7042	0,6965	-0,0077

- Hyperparameter tuning tidak berhasil meningkatkan performa model (dalam accuracy).
- Namun, Recall meningkat dari 73,02% menjadi 78,51%.
- Model lebih baik dalam mengidentifikasi individu dengan pendapatan >50K.

EVALUASI KINERJA MODEL AKHIR

Kelas	Precision	Recall	F1-score	Support
0($\leq 50k$)	0,91	0,89	0,90	4.940
1(>50k)	0,68	0,73	0,70	1.568
Accuracy	-	-	0,8522	6.508
Macro avg	0,80	0,81	0,80	6.508
Weighted avg	0,86	0,85	0,85	6.508



Pada kelas 0 atau pendapatan $\leq 50K$, model memperoleh precision sebesar 0,91, recall sebesar 0,89, dan F1-score sebesar 0,90. Pada kelas 1 atau pendapatan $> 50K$, model memperoleh precision sebesar 0,68, recall sebesar 0,73, dan F1-score sebesar 0,70. Perbedaan performa antar kelas dipengaruhi oleh distribusi data ui yang tidak seimbang dimana kelas $\leq 50K$ mendominasi sebesar 75,91%

Secara keseluruhan, accuracy model final sebesar 0,8522 atau 85,22%. Nilai macro average sebesar 0,80 pada seluruh metrik menunjukkan model bekerja cukup baik pada kedua kelas, meskipun terdapat kesenjangan yang wajar antara kelas mayoritas dan minoritas akibat distribusi data uji yang tidak seimbang.

ANALISIS CONFUSION MATRIX

TRUE NEGATIVE (TN)


4401 data

Individu dengan pendapatan $\leq 50K$ berhasil diprediksi dengan benar sebagai $\leq 50K$.

FALSE NEGATIVE (FN)

4723 data

Individu dengan pendapatan $> 50K$ diprediksi sebagai $\leq 50K$ sehingga model gagal mengenali kelas pendapatan tinggi.



FALSE POSITIVE (FP)

539 data

Individu dengan pendapatan $\leq 50K$ diprediksi sebagai $> 50K$ sehingga terjadi kesalahan klasifikasi ke kelas pendapatan tinggi.



TRUE POSITIVE (TP)

1145 data



Individu dengan pendapatan $> 50K$ berhasil diprediksi dengan benar sebagai $> 50K$.

INTERPRETASI

- Model berhasil mengklasifikasikan 8.856 dari 9.880 data uji dengan benar
- Nilai Recall kelas $> 50K$ sebesar 73,02% menunjukkan model efektif dalam mengidentifikasi individu berpendapatan tinggi.



ANALISIS ROC-AUC & FEATURE IMPORTANCE




Analisis ROC-AUC

Nilai ROC-AUC sebesar 0,90971 menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam membedakan individu dengan pendapatan $\leq 50K$ dan $>50K$. Nilai yang mendekati 1,0 menandakan bahwa model mampu melakukan klasifikasi secara akurat dan efektif pada berbagai threshold, sehingga performa model dapat dikatakan sangat baik.

Analisis Feature Importance

Fitur relationship merupakan faktor yang paling berpengaruh dalam prediksi pendapatan, diikuti oleh education.num, marital.status, dan capital.gain. Hasil ini menunjukkan bahwa hubungan dalam keluarga, tingkat pendidikan, status pernikahan, dan keuntungan investasi memiliki kontribusi terbesar terhadap tingkat pendapatan individu.




KESIMPULAN & SARAN

KESIMPULAN

1. Faktor sosial (relationship, marital.status, education.num) & finansial (capital.gain) mendominasi prediksi pendapatan.
2. Tahap preprocessing (imputasi, encoding, standardisasi) berhasil menyiapkan data tanpa data leakage.
3. Penerapan SMOTE hanya pada data latih sukses menyeimbangkan kelas minoritas (>50K).
4. XGBoost Default adalah model terbaik dengan Accuracy 85,22% dan ROC-AUC 0,9097 pada dataset Adult Census Income.

SARAN

1. Bandingkan performa XGBoost dengan algoritma lain seperti LightGBM, CatBoost, atau ANN.
2. Gunakan metode hyperparameter tuning yang lebih komprehensif seperti Bayesian Optimization atau Optuna.
3. Gunakan dataset yang lebih besar/mutakhir atau tambahkan variabel sosial-ekonomi baru.
4. Kembangkan model menjadi sistem pendukung keputusan atau aplikasi prediksi tingkat pendapatan.



THANK

WELL DONE~
YOU

SO

MUCH!!!~

ANY QUESTION?

