

LAPORAN PROJECT MACHINE LEARNING
PEMANFAATAN MACHINE LEARNING DALAM
MENGIDENTIFIKASI KARAKTERISTIK INDIVIDU YANG
BERPENGARUH TERHADAP TINGKAT PENDAPATAN



Disusun untuk memenuhi tugas terstruktur :

Mata kuliah : Machine Learning

Dosen : Lutfiah Maharani Siniwi, M.Stat.

DISUSUN OLEH:

- | | |
|--------------------------------|-------------|
| 1. Carrisa Putri Arabella | (K1D024019) |
| 2. Faricha Cahya Metia | (K1D024023) |
| 3. Fatihaturrohman | (K1D024035) |
| 4. Aditya Febrio Setiawan | (K1D024036) |
| 5. Andhika Pradana Rahma Dhany | (K1D024038) |

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
UNIVERSITAS JENDERAL SOEDIRMAN
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI STATISTIKA
PURWOKERTO

2026

DAFTAR ISI

DAFTAR ISI.....	ii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	2
1.3 Tujuan Penelitian	2
1.4 Manfaat.....	3
BAB II TINJAUAN DATASET.....	5
2.1 Sumber Dataset.....	5
2.2 Deskripsi Dataset	5
2.3 Penjelasan Variabel (Fitur).....	6
2.4 Statistik Deskriptif	8
2.5 Target Variabel	9
BAB III METODOLOGI	10
3.1 Exploratory Data Analysis (EDA).....	10
3.2 Preprocessing Data.....	10
3.2.1 Penanganan Missing Value.....	10
3.2.2 Penanganan Data Duplikat.....	10
3.2.3 Penanganan Outlier.....	11
3.2.4 Transformasi Data Kategorikal	11
3.2.5 Standardisasi Data	11
3.3 Pembentukan Variabel	12
3.4 Penanganan Ketidakseimbangan Data.....	12
3.5 Pemodelan Machine Learning.....	12
3.6 Pembagian Data	13
BAB IV HASIL DAN PEMBAHASAN.....	14
4.1 Hasil Pemodelan	14
4.2 Evaluasi Model Final	15
4.2.1 Hasil Hyperparameter Tuning.....	15
4.2.2 Classification Report Model Final	16
4.2.3 Confusion Matrix.....	16
4.2.4 ROC-AUC.....	17

4.3 Interpretasi Model	18
4.3.1 Feature Importance	18
4.3.2 Interpretasi SHAP	19
4.4 Pembahasan	20
4.4.1 Pembahasan Performa Model	20
4.4.2 Analisis Overfitting dan Underfitting.....	20
4.4.3 Pembahasan Penanganan Class Imbalance.....	22
BAB V PENUTUP	23
5.1 Kesimpulan	23
5.2 Saran	23
LAMPIRAN	25

DAFTAR TABEL

Tabel 2.1 Deskripsi Dataset Adult Census Income	5
Tabel 2.2 Deskripsi Variabel Dataset Adult Census Income	6
Tabel 2.3 Statistik Deskriptif Variabel Numerik	8
Tabel 4.1 Perbandingan Performa Model Klasifikasi	14
Tabel 4.2 Parameter Optimal Model Tuned XGBoost.....	15
Tabel 4.3 Perbandingan XGBoost Sebelum dan Sesudah Tuning	15
Tabel 4.4 Classification Report Model Final (XGBoost Default)	16
Tabel 4.5 Confusion Matrix Model Final XGBoost Default	16
Tabel 4.6 Feature Importance Model XGBoost	18
Tabel 4.7 Ringkasan Perbandingan Seluruh Model.....	20
Tabel 4.8 Ringkasan Learning Curve XGBoost Default	21

DAFTAR GAMBAR

Gambar 4.1 Confusion Matrix Model Final XGBoost Default	17
Gambar 4.2 Kurva ROC XGBoost.....	17
Gambar 4.3 SHAP Summary Plot (Beeswarm)	19
Gambar 4.4 Learning Curve Model XGBoost Default	21

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kesenjangan pendapatan kini menjadi fenomena yang semakin mencolok di tengah arus globalisasi dan pertumbuhan ekonomi, sehingga memerlukan perhatian serius dari pemerintah dalam merumuskan kebijakan redistribusi pendapatan yang lebih adil. Kebijakan redistribusi ini mencakup berbagai instrumen penting, mulai dari penerapan sistem pajak progresif hingga penyusunan program kesejahteraan yang dirancang khusus untuk memberikan dukungan nyata kepada kelompok masyarakat rentan. Namun, implementasi di lapangan sering kali menghadapi tantangan berat karena melibatkan pertimbangan yang sangat kompleks terkait efektivitas ekonomi, keadilan sosial, dan keseimbangan politik, sehingga diperlukan evaluasi yang mendalam dan berkelanjutan terhadap model kebijakan yang ada.

Di sisi lain, ketimpangan distribusi pendapatan yang membedakan ukuran penerimaan antara masyarakat golongan atas dan bawah terbukti dapat memicu masalah sosial dan ketidakstabilan ekonomi yang serius jika terus dibiarkan. Masalah perekonomian pelik yang dihadapi negara berkembang, seperti angka kemiskinan yang tinggi, pengangguran, serta kurangnya lapangan kerja, sering kali membuat program penurunan angka ketimpangan ekonomi menjadi tidak berjalan optimal. Dampaknya, target indikator kesejahteraan nasional seperti penurunan nilai *Gini Ratio* yang telah ditetapkan dalam Rencana Pembangunan Jangka Menengah Nasional (RPJMN) sering kali gagal dicapai akibat distribusi pendapatan yang belum merata di seluruh lapisan masyarakat.

Hambatan utama yang sering membuat program penurunan ketimpangan tersebut menjadi kurang optimal adalah proses pengumpulan data kesejahteraan masyarakat yang masih mengandalkan cara manual. Sensus konvensional di lapangan membutuhkan waktu yang lama serta biaya yang besar, sehingga data yang sampai ke tangan pembuat kebijakan sering kali sudah terlambat dan tidak sesuai lagi dengan kondisi riil di masyarakat. Guna mengatasi kendala tersebut, penggunaan teknologi *machine learning* dapat menjadi solusi alternatif untuk mempercepat pemetaan data. Dalam proyek ini, simulasi pemetaan dilakukan dengan memanfaatkan dataset *Adult Census Income* dari Kaggle. Dataset ini dipilih karena menyediakan data terstruktur yang lengkap mengenai karakteristik penduduk dunia nyata, seperti variabel usia, tingkat pendidikan, pekerjaan, hingga jam

kerja per minggu yang sangat relevan untuk memprediksi kelompok pendapatan masyarakat.

Melalui dataset dari Kaggle tersebut, proyek ini berfokus pada penerapan dan perbandingan beberapa algoritma klasifikasi biner untuk melihat model mana yang paling akurat dalam menebak tingkat pendapatan individu. Proses pengolahan data di dalam penelitian ini dirancang secara terstruktur, mulai dari tahap pembersihan data agar terhindar dari kebocoran informasi (*data leakage*), hingga penanganan jumlah data yang tidak seimbang (*class imbalance*) agar hasil prediksi dari model yang dibuat tidak berat sebelah. Dengan adanya eksperimen komparasi ini, hasil akhir proyek diharapkan dapat memberikan gambaran yang jelas mengenai bagaimana sistem komputasi dapat membantu mengelompokkan profil ekonomi masyarakat secara otomatis, cepat, dan objektif.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, rumusan masalah yang akan diselesaikan dalam proyek akhir *Machine Learning* ini adalah sebagai berikut:

1. Karakteristik sosio-demografi apa saja (seperti usia, tingkat pendidikan, status pernikahan, jenis pekerjaan, dan jam kerja per minggu) yang memiliki korelasi atau pengaruh paling dominan terhadap tingkat pendapatan individu?
2. Bagaimana memproses data mentah *Adult Census Income* termasuk penanganan nilai yang hilang (*missing values*), penyandian variabel kategorik (*encoding*), dan pembersihan data agar siap digunakan dalam pemodelan tanpa memicu kebocoran data (*data leakage*)?
3. Bagaimana teknik *feature engineering* dan penanganan data tidak seimbang (*class imbalance*) digunakan supaya model yang dihasilkan adil dan tidak berat sebelah?
4. Algoritma *Machine Learning* manakah di antara tiga model klasifikasi pembanding yang digunakan yang mampu memberikan performa prediksi terbaik dan paling stabil berdasarkan metrik evaluasi yang tepat (*Accuracy, Precision, Recall, F1-score*, dan *ROC-AUC*) setelah dilakukan *hyperparameter tuning*?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan, tujuan yang ingin dicapai dalam pelaksanaan proyek akhir *Machine Learning* ini adalah sebagai berikut:

1. Menganalisis karakteristik sosio-demografi individu (seperti usia, tingkat pendidikan, status pernikahan, jenis pekerjaan, dan jam kerja per minggu) melalui Eksplorasi Data

Analisis (EDA) guna mengidentifikasi faktor yang memiliki pengaruh atau korelasi paling dominan terhadap tingkat pendapatan.

2. Menerapkan tahapan *preprocessing* data mentah *Adult Census Income* yang tepat—meliputi penanganan nilai yang hilang (*missing values*), penyandian variabel kategorik (*encoding*), dan pembersihan data secara aman untuk mencegah terjadinya kebocoran data (*data leakage*).
3. Mengimplementasikan teknik rekayasa fitur (*feature engineering*) serta metode penanganan ketidakseimbangan kelas (*class imbalance*) guna memastikan model *machine learning* yang dibangun dapat memberikan prediksi yang adil dan tidak bias terhadap kelas mayoritas.
4. Mengevaluasi dan membandingkan performa prediksi serta stabilitas dari tiga algoritma *machine learning* pilihan setelah melalui proses *hyperparameter tuning*, dengan menggunakan metrik evaluasi yang komprehensif (*Accuracy*, *Precision*, *Recall*, *F1-score*, dan *ROC-AUC*).

1.4 Manfaat

Manfaat yang dapat diperoleh dari hasil pengerjaan proyek akhir *Machine Learning* ini adalah sebagai berikut:

1. Manfaat Praktis

a. Bagi Sektor Publik / Pemerintah

Menghasilkan model prediksi berbasis *data science* untuk memetakan tingkat kesejahteraan masyarakat secara cepat dan akurat. Melalui pemanfaatan kecerdasan buatan ini, perumusan kebijakan fiskal, penentuan kuota subsidi, serta penyaluran program bantuan sosial (bansos) dapat dieksekusi secara lebih adaptif dan tepat sasaran. Pendekatan digital ini sekaligus mampu memangkas biaya logistik yang masif serta mengeliminasi keterlambatan data yang kerap terjadi jika hanya bergantung pada proses sensus manual konvensional yang memakan waktu lama.

b. Bagi Sektor Privat / Industri Finansial

Memberikan kontribusi nyata sebagai acuan atau kerangka pemodelan prediktif dalam mengoptimalkan pemanfaatan data karakteristik demografi konsumen berskala besar. Model ini dapat dikembangkan oleh pihak swasta untuk mempertajam strategi segmentasi pasar (*market segmentation*), meningkatkan akurasi penilaian kelayakan kredit (*credit scoring*) bagi calon nasabah, serta

membangun sistem manajemen risiko keuangan yang bekerja secara otomatis, presisi, dan efisien.

2. Manfaat Akademis

a. Bagi Mahasiswa dan Peneliti

Menyajikan panduan dan contoh praktis mengenai bagaimana mengimplementasikan seluruh tahapan alur kerja *machine learning* secara komprehensif pada jenis data terstruktur atau tabular. Penelitian ini sangat bernilai untuk memperdalam pemahaman teknis terkait proses pembersihan data yang aman guna mengeliminasi risiko kebocoran informasi, sekaligus memberikan strategi nyata dalam memanipulasi ketidakseimbangan kelas data (*class imbalance*) agar model yang dilatih dapat memberikan keputusan prediksi yang adil, objektif, dan tidak condong pada kelompok mayoritas saja.

b. Bagi Perkembangan Ilmu Sains Data

Menyediakan laporan eksperimen yang rapi dan jelas mengenai perbandingan performa dari beberapa algoritma klasifikasi. Hasil pengujian yang menggunakan berbagai metrik seperti *Accuracy*, *Precision*, *Recall*, *F1-score*, dan *ROC-AUC* setelah penyetelan parameter (*hyperparameter tuning*) ini dapat dijadikan referensi atau bahan perbandingan untuk penelitian selanjutnya.

BAB II TINJAUAN DATASET

2.1 Sumber Dataset

Dataset yang digunakan dalam penelitian ini adalah Adult Census Income Dataset yang bersumber dari UCI Machine Learning Repository. Dataset ini dapat diakses secara publik melalui tautan: <https://share.google/4kgGzqt1a4oJl7kvR>. Data tersebut diekstrak dari basis data Census tahun 1994 oleh Barry Becker dan dipublikasikan di UCI Repository. Dataset ini merupakan salah satu benchmark klasik yang banyak digunakan dalam penelitian machine learning, khususnya untuk tugas klasifikasi biner.

Dataset Adult Census Income bertujuan untuk memprediksi apakah pendapatan tahunan seorang individu melebihi USD 50.000 atau tidak berdasarkan atribut demografis dan kondisi pekerjaan. Masalah ini dikenal sebagai binary classification problem dengan dua kelas output, yaitu $\leq 50K$ dan $> 50K$.

2.2 Deskripsi Dataset

Dataset Adult Census Income memiliki karakteristik sebagai berikut:

Tabel 2.1 Deskripsi Dataset Adult Census Income

Atribut	Keterangan
Sumber Data	UCI Machine Learning Repository – Adult Census Income Dataset
Jumlah Baris	32.561 observasi
Jumlah Kolom	15 fitur (14 fitur input + 1 target variable)
Fitur Numerik	6 kolom: age, fnlwgt, education.num, capital.gain, capital.loss, hours.per.week
Fitur Kategorikal	8 kolom: workclass, education, marital.status, occupation, relationship, race, sex, native.country
Target Variable	income (binary: $\leq 50K$ atau $> 50K$)
Missing Value	Terdapat pada kolom workclass (1.836), occupation (1.843), dan native.country (583) dikodekan sebagai '?'

Berdasarkan Tabel 2.1, dataset terdiri dari 32.561 baris observasi dan 15 kolom variabel. Dari keseluruhan fitur, 6 bersifat numerik (kontinyu maupun diskrit) dan 8 bersifat kategorikal. Variabel target (income) bersifat kategorikal biner. Dataset ini mengandung nilai hilang (missing values) yang dikodekan sebagai tanda tanya (?) pada tiga kolom, yaitu workclass, occupation, dan native.country.

Distribusi kelas pada variabel target menunjukkan ketidakseimbangan (class imbalance), di mana 75,9% observasi termasuk kelas $\leq 50K$ dan 24,1% termasuk kelas $> 50K$. Kondisi ini perlu diperhatikan dalam proses pemodelan agar tidak terjadi bias prediksi terhadap kelas mayoritas.

2.3 Penjelasan Variabel (Fitur)

Berikut adalah penjelasan lengkap untuk setiap variabel yang terdapat dalam dataset Adult Census Income:

Tabel 2.2 Deskripsi Variabel Dataset Adult Census Income

No.	Nama Kolom	Tipe Data	Kategori	Deskripsi
1	age	Numerik	—	Usia individu (dalam tahun). Rentang nilai: 17–90 tahun, rata-rata 38,58 tahun.
2	workclass	Kategorikal	Private, Self-emp, Gov, dll.	Jenis sektor pekerjaan individu. Terdapat 9 kategori termasuk '?' sebagai nilai hilang (1.836 baris).
3	fnlwgt	Numerik	—	Final weight, bobot yang diberikan Census Bureau untuk merepresentasikan jumlah penduduk dengan karakteristik serupa di populasi.
4	education	Kategorikal	HS-grad, Bachelors, dll.	Tingkat pendidikan tertinggi yang dicapai individu. Terdiri dari 16 kategori mulai dari Preschool hingga Doctorate.
5	education.num	Numerik	—	Representasi numerik dari kolom education. Nilai 1 (terendah) hingga 16 (Doctorate), rata-rata 10,08.

6	marital.status	Kategorikal	Married, Divorced, dll.	Status pernikahan individu. Terdiri dari 7 kategori.
7	occupation	Kategorikal	Exec-managerial, Sales, dll.	Jenis pekerjaan individu. Terdapat 14 kategori unik termasuk '?' sebagai nilai hilang (1.843 baris).
8	relationship	Kategorikal	Husband, Wife, dll.	Peran individu dalam hubungan keluarga. Terdiri dari 6 kategori: Husband, Wife, Own-child, Not-in-family, Other-relative, Unmarried.
9	race	Kategorikal	White, Black, dll.	Ras individu. Terdapat 5 kategori: White, Black, Asian-Pac-Islander, Amer-Indian-Eskimo, Other.
10	sex	Kategorikal	Male, Female	Jenis kelamin individu. Terdiri dari 2 kategori: Male dan Female.
11	capital.gain	Numerik	—	Keuntungan modal (capital gain) dari investasi. Sebagian besar bernilai 0; rata-rata 1.077,65.
12	capital.loss	Numerik	—	Kerugian modal (capital loss) dari investasi. Sebagian besar bernilai 0; rata-rata 87,30.
13	hours.per.week	Numerik	—	Jumlah jam kerja per minggu. Rentang nilai: 1–99 jam, rata-rata 40,44 jam.
14	native.country	Kategorikal	United-States, Mexico, dll.	Negara asal individu. Terdapat 42 negara unik termasuk '?' sebagai nilai hilang (583 baris). Mayoritas berasal dari United-States.
15	income	Kategorikal (Target)	<=50K, >50K	Variabel target: klasifikasi pendapatan individu. <=50K: 24.720 (75,9%), >50K: 7.841 (24,1%).

Berdasarkan Tabel 2.2, terdapat beberapa hal penting yang perlu diperhatikan:

- Kolom `education` dan `education.num` merepresentasikan informasi yang sama secara substansif. Kolom `education.num` adalah versi numerik dari kolom `education`, sehingga salah satu dapat dihapus untuk menghindari multikolinearitas.
- Kolom `capital.gain` dan `capital.loss` mencatat aktivitas investasi individu. Sebagian besar individu memiliki nilai 0 pada kedua kolom ini, menandakan distribusi yang sangat skewed ke kanan.
- Kolom `fnlwgt` merupakan bobot statistik yang ditetapkan oleh Census Bureau dan umumnya tidak relevan secara langsung dalam prediksi pendapatan.
- Tiga kolom mengandung nilai hilang yang dikodekan sebagai '?': `workclass` (1.836 baris, 5,64%), `occupation` (1.843 baris, 5,66%), dan `native.country` (583 baris, 1,79%). Penanganan nilai hilang ini perlu dilakukan sebelum pemodelan.

2.4 Statistik Deskriptif

Ringkasan statistik deskriptif untuk keenam variabel numerik dalam dataset disajikan pada tabel berikut:

Tabel 2.3 Statistik Deskriptif Variabel Numerik

Variabel	Min	Max	Mean	Median	Std Dev	Q3
age	17	90	38,58	37	13,64	48
fnlwgt	12.285	1.484.705	189.778	178.356	105.550	237.051
education.num	1	16	10,08	10	2,57	12
capital.gain	0	99.999	1.077,65	0	7.385,29	0
capital.loss	0	4.356	87,30	0	402,96	0
hours.per.week	1	99	40,44	40	12,35	45

Berdasarkan Tabel 2.3, variabel `age` memiliki rentang usia 17–90 tahun dengan rata-rata 38,58 tahun, menggambarkan populasi usia kerja yang beragam. Variabel `fnlwgt` memiliki nilai yang sangat besar dan variansi tinggi karena merepresentasikan bobot populasi. Variabel `education.num` menunjukkan rata-rata setara dengan tingkat SMA (HS-grad). Variabel `capital.gain` dan `capital.loss` memiliki nilai median 0, yang mengindikasikan bahwa mayoritas individu tidak melaporkan transaksi modal. Variabel

hours.per.week menunjukkan rata-rata jam kerja 40,44 jam per minggu yang mendekati standar kerja penuh waktu.

2.5 Target Variabel

Variabel target dalam dataset ini adalah income, yang merupakan variabel biner dengan dua nilai:

- a. $\leq 50K$: Pendapatan tahunan individu kurang dari atau sama dengan USD 50.000. Terdapat 24.720 observasi (75,9% dari total data).
- b. $> 50K$: Pendapatan tahunan individu lebih dari USD 50.000. Terdapat 7.841 observasi (24,1% dari total data).

Ketidakseimbangan kelas sebesar kurang lebih 3:1 ($\leq 50K$ vs $> 50K$) merupakan karakteristik penting yang harus dipertimbangkan dalam pemilihan metode klasifikasi dan metrik evaluasi model. Penggunaan accuracy saja tidak mencukupi; metrik seperti precision, recall, F1-score, dan AUC-ROC lebih direkomendasikan untuk mengevaluasi performa model pada dataset tidak seimbang.

BAB III

METODOLOGI

3.1 Exploratory Data Analysis (EDA)

Pada tahap awal dilakukan Exploratory Data Analysis (EDA) untuk memahami karakteristik dataset Adult Census Income. Analisis dilakukan dengan memeriksa tipe data setiap variabel, statistik deskriptif, distribusi data, korelasi antarvariabel, serta visualisasi data menggunakan histogram, boxplot, scatter plot, dan heatmap korelasi.

Selain itu dilakukan identifikasi missing value, data duplikat, dan outlier untuk mengetahui kualitas data sebelum memasuki tahap pemodelan. Hasil EDA menunjukkan bahwa dataset memiliki 32.561 observasi dan 15 variabel, dengan kombinasi fitur numerik dan kategorikal.

3.2 Preprocessing Data

Tahap preprocessing dilakukan untuk mempersiapkan data agar dapat digunakan dalam proses machine learning.

3.2.1 Penanganan Missing Value

Pemeriksaan awal menggunakan fungsi `isnull()` menunjukkan tidak terdapat nilai null pada dataset. Namun, ditemukan simbol '?' pada beberapa variabel kategorikal yang sebenarnya merepresentasikan data yang hilang, yaitu:

- Workclass
- Occupation
- Native Country

Nilai '?' tersebut kemudian diubah menjadi NaN agar dapat dikenali oleh library pandas, lalu diimputasi menggunakan nilai modus dari masing-masing variabel. Pemilihan metode imputasi modus dilakukan karena ketiga variabel tersebut bersifat kategorikal, sehingga nilai yang paling sering muncul dianggap paling representatif untuk menggantikan data yang hilang tanpa mengubah distribusi kategori secara signifikan.

3.2.2 Penanganan Data Duplikat

Pemeriksaan data duplikat dilakukan menggunakan fungsi `duplicated()` pada seluruh kolom dataset. Hasil pemeriksaan menemukan 24 baris data yang terduplikasi secara identik. Seluruh data duplikat tersebut kemudian dihapus menggunakan fungsi `drop_duplicates()` sehingga jumlah data berkurang dari 32.561 menjadi 32.537 observasi.

Penghapusan ini dilakukan agar model tidak bias akibat data yang sama dipelajari lebih dari satu kali.

3.2.3 Penanganan Outlier

Deteksi outlier dilakukan menggunakan metode Interquartile Range (IQR) pada seluruh fitur numerik. Berdasarkan hasil deteksi, outlier ditemukan pada beberapa variabel seperti age, fnlwgt, education.num, capital.gain, capital.loss, dan hours.per.week.

Pada penelitian ini, outlier tidak dihapus karena dianggap sebagai data valid yang merepresentasikan kondisi nyata populasi sensus, misalnya individu dengan usia lanjut yang masih bekerja atau individu dengan capital.gain yang sangat tinggi. Nilai-nilai tersebut justru memiliki informasi penting dalam membedakan kelompok pendapatan, sehingga tetap dipertahankan agar model dapat mempelajari variasi data secara utuh.

3.2.4 Transformasi Data Kategorikal

Variabel kategorikal pada dataset ditransformasikan menjadi bentuk numerik menggunakan metode Label Encoding agar dapat diproses oleh algoritma machine learning yang hanya menerima input numerik. Variabel yang ditransformasikan meliputi workclass, education, marital.status, occupation, relationship, race, dan native.country. Setiap kategori pada variabel tersebut diberikan nilai integer unik berdasarkan urutan kemunculannya, sehingga struktur data tetap konsisten digunakan pada proses pelatihan maupun pengujian model.

3.2.5 Standardisasi Data

Fitur numerik pada dataset distandarisasi menggunakan metode Standardization (Z-score) sehingga setiap fitur memiliki rata-rata mendekati 0 dan standar deviasi mendekati 1. Proses ini penting dilakukan terutama untuk algoritma yang sensitif terhadap skala data, seperti Logistic Regression, agar tidak ada satu fitur pun yang mendominasi proses pembelajaran model hanya karena memiliki rentang nilai yang lebih besar.

Variabel yang distandarisasi meliputi:

- age
- fnlwgt
- education.num
- capital.gain
- capital.loss

- hours.per.week

3.3 Pembentukan Variabel

Dataset kemudian dipisahkan menjadi:

- Variabel independen (X) berupa seluruh fitur prediktor.
- Variabel dependen (y) berupa variabel income.

Variabel income digunakan sebagai target klasifikasi dengan dua kelas:

- 0 : Pendapatan $\leq$ 50K
- 1 : Pendapatan $>$ 50K

3.4 Penanganan Ketidakseimbangan Data

Distribusi variabel target menunjukkan adanya ketidakseimbangan kelas (class imbalance), di mana kelas pendapatan $\leq$ 50K memiliki proporsi yang jauh lebih besar dibandingkan kelas $>$ 50K. Apabila dibiarkan, ketidakseimbangan ini dapat menyebabkan model lebih condong memprediksi kelas mayoritas dan kurang sensitif dalam mendeteksi kelas minoritas.

Untuk mengatasi masalah tersebut, digunakan metode Synthetic Minority Oversampling Technique (SMOTE) yang bekerja dengan cara membuat data sintetis baru pada kelas minoritas berdasarkan interpolasi antar data terdekat. Penerapan SMOTE dilakukan hanya pada data training agar tidak terjadi data leakage ke data testing, sehingga menghasilkan distribusi kelas yang seimbang sebelum proses pelatihan model dilakukan.

3.5 Pemodelan Machine Learning

Penelitian ini menggunakan tiga algoritma klasifikasi, yaitu:

1. Logistic Regression

Logistic Regression digunakan sebagai model baseline karena sederhana, mudah diinterpretasikan, dan umum digunakan pada permasalahan klasifikasi biner.

2. Random Forest

Random Forest dipilih karena mampu menangani data dengan hubungan non-linear, tahan terhadap outlier, serta memiliki performa yang baik pada data dengan banyak fitur.

3. XGBoost

XGBoost dipilih karena merupakan algoritma boosting yang mampu meningkatkan akurasi prediksi melalui pembelajaran bertahap dan sering menghasilkan performa terbaik pada kasus klasifikasi.

3.6 Pembagian Data

Data yang telah melalui proses preprocessing dibagi menjadi data training dan data testing menggunakan metode train-test split dengan proporsi 80% data training dan 20% data testing

Data training digunakan untuk membangun model, sedangkan data testing digunakan untuk mengukur kemampuan model dalam melakukan prediksi pada data yang belum pernah dilihat sebelumnya.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Pemodelan

Pada penelitian ini digunakan tiga algoritma klasifikasi, yaitu Logistic Regression, Random Forest, dan XGBoost. Logistic Regression berperan sebagai model baseline karena memiliki struktur sederhana dan mudah diinterpretasikan. Random Forest dan XGBoost berperan sebagai model pembanding berbasis ensemble tree karena mampu menangkap pola non-linear pada data. Sebelum pemodelan, data diseimbangkan menggunakan SMOTE yang diterapkan hanya pada data latih setelah train-test split untuk mencegah data leakage. Ketiga model dievaluasi pada data uji sebanyak 6.508 observasi dengan distribusi asli (75,91% kelas $\leq 50K$ dan 24,09% kelas $> 50K$).

Pemilihan model terbaik didasarkan pada F1-Score kelas 1 (income $> 50K$) sebagai metrik utama, karena F1-Score merupakan rata-rata harmonik Precision dan Recall yang lebih representatif untuk kondisi class imbalance dibandingkan accuracy semata. Perbandingan performa ketiga model pada data uji disajikan pada Tabel 4.1.

Tabel 4.1 Perbandingan Performa Model Klasifikasi

Model	Accuracy	Precision ($> 50K$)	Recall ($> 50K$)	F1-Score ($> 50K$)	AUC
Logistic Regression	0,7698	0,52	0,76	0,61	0,849
Random Forest	0,8364	0,65	0,70	0,67	0,892
XGBoost	0,8522	0,68	0,73	0,70	0,910

Berdasarkan Tabel 4.1, Logistic Regression memperoleh accuracy sebesar 0,7698 dengan F1-Score kelas 1 terendah (0,61). Meskipun recall kelas 1-nya relatif tinggi (0,76), precision yang sangat rendah (0,52) menunjukkan bahwa model terlalu agresif dalam memprediksi kelas $> 50K$ sehingga menghasilkan banyak False Positive. Random Forest menghasilkan accuracy 0,8364 dengan F1-Score kelas 1 sebesar 0,67, menunjukkan peningkatan signifikan dibandingkan baseline. XGBoost menghasilkan accuracy tertinggi sebesar 0,8522 sekaligus F1-Score kelas 1 tertinggi (0,70) dan AUC terbaik (0,910), sehingga dipilih sebagai model terbaik untuk dilanjutkan ke tahap hyperparameter tuning.

4.2 Evaluasi Model Final

4.2.1 Hasil Hyperparameter Tuning

Hyperparameter tuning dilakukan pada model XGBoost menggunakan RandomizedSearchCV dengan 50 kombinasi parameter dan 3-fold cross-validation. Scoring tuning ditetapkan pada F1-Score kelas 1 agar optimasi fokus memaksimalkan keseimbangan antara Precision dan Recall dalam mendeteksi individu berpenghasilan >50K. Proses tuning menghasilkan nilai F1-Score cross-validation terbaik sebesar 0,8625. Kombinasi parameter terbaik yang diperoleh ditampilkan pada Tabel 4.2.

Tabel 4.2 Parameter Optimal Model Tuned XGBoost

Parameter	Nilai Optimal	Fungsi
n_estimators	100	Jumlah pohon dalam ensemble
max_depth	5	Kedalaman maksimum tiap pohon
learning_rate	0,1	Kecepatan belajar (shrinkage)
subsample	0,7	Proporsi sampel training per pohon
colsample_bytree	0,9	Proporsi fitur yang digunakan per pohon
gamma	0	Ambang batas minimum loss reduction

Setelah dilakukan tuning, perbandingan performa XGBoost sebelum dan sesudah tuning berdasarkan F1-Score ditampilkan pada Tabel 4.3.

Tabel 4.3 Perbandingan XGBoost Sebelum dan Sesudah Tuning

Metrik	Sebelum Tuning (Default)	Sesudah Tuning (F1-scoring)	Perubahan
Accuracy	0,8522	0,8351	-0,0171
Precision kelas 1 (>50K)	0,6799	0,6258	-0,0541
Recall kelas 1 (>50K)	0,7302	0,7851	+0,0549
F1-Score kelas 1 (>50K)	0,7042	0,6965	-0,0077

Berdasarkan Tabel 4.3, tuning dengan scoring F1 menghasilkan peningkatan recall kelas 1 dari 0,7302 menjadi 0,7851 (+0,0549). Namun, precision kelas 1 justru menurun cukup signifikan dari 0,6799 menjadi 0,6258 (-0,0541), sehingga F1-Score akhir turun dari 0,7042 menjadi 0,6965 (-0,0077). Accuracy juga turun dari 0,8522 menjadi 0,8351. Karena F1-Score model tuned lebih rendah dibandingkan model default, maka XGBoost

Default ditetapkan sebagai model final. Hal ini menunjukkan bahwa parameter default XGBoost sudah sangat optimal untuk dataset ini.

4.2.2 Classification Report Model Final

Model akhir yang digunakan adalah XGBoost Default. Hasil classification report model final pada data uji ditampilkan pada Tabel 4.4.

Tabel 4.4 Classification Report Model Final (XGBoost Default)

Kelas	Precision	Recall	F1-Score	Support
0 ($\leq 50K$)	0,91	0,89	0,90	4.940
1 ($> 50K$)	0,68	0,73	0,70	1.568
Accuracy	—	—	0,8522	6.508
Macro avg	0,80	0,81	0,80	6.508
Weighted avg	0,86	0,85	0,85	6.508

Pada kelas 0 (pendapatan $\leq 50K$), model memperoleh precision sebesar 0,91, recall sebesar 0,89, dan F1-Score sebesar 0,90. Pada kelas 1 (pendapatan $> 50K$), model memperoleh precision sebesar 0,68, recall sebesar 0,73, dan F1-Score sebesar 0,70. Perbedaan performa antar kelas ini dipengaruhi oleh distribusi data uji yang tidak seimbang, di mana kelas $\leq 50K$ mendominasi sebesar 75,91%.

Secara keseluruhan, accuracy model final sebesar 0,8522 atau 85,22%. Nilai macro average sebesar 0,80 pada seluruh metrik menunjukkan model bekerja cukup baik pada kedua kelas, meskipun terdapat kesenjangan yang wajar antara kelas mayoritas dan minoritas akibat distribusi data uji yang tidak seimbang.


4.2.3 Confusion Matrix

Confusion matrix digunakan untuk melihat distribusi prediksi benar dan salah pada masing-masing kelas. Hasil confusion matrix model final XGBoost Default ditampilkan pada Tabel 4.5.

Tabel 4.5 Confusion Matrix Model Final XGBoost Default

Aktual / Prediksi	Prediksi $\leq 50K$	Prediksi $> 50K$	Total Aktual
Aktual $\leq 50K$	4.413 (TN)	527 (FP)	4.940
Aktual $> 50K$	423 (FN)	1.145 (TP)	1.568

Visualisasi confusion matrix model final ditampilkan pada Gambar 4.1 berikut ini.




Gambar 4.1 *Confusion Matrix* Model Final XGBoost Default

Berdasarkan Tabel 4.5 dan Gambar 4.1, model berhasil memprediksi 4.413 observasi kelas $\leq 50K$ (TN) dan 1.145 observasi kelas $> 50K$ (TP) dengan benar. Terdapat 527 False Positive (FP) — individu $\leq 50K$ yang salah diprediksi $> 50K$, dan 423 False Negative (FN) — individu $> 50K$ yang tidak terdeteksi. Total kesalahan prediksi sebesar 950 dari 6.508 data uji ($\approx 14,60\%$). Nilai FN lebih kecil dari FP menunjukkan bahwa model cukup sensitif dalam mengenali kelas $> 50K$, selaras dengan recall kelas 1 sebesar 0,7302.

4.2.4 ROC-AUC

Evaluasi tambahan dilakukan menggunakan metrik ROC-AUC untuk mengukur kemampuan diskriminasi model pada berbagai threshold. Kurva ROC model final XGBoost Default beserta perbandingannya dengan model lain ditampilkan pada Gambar 4.2.



Gambar 4.2 Kurva ROC XGBoost

Berdasarkan Gambar 4.2, model final XGBoost memperoleh nilai AUC sebesar 0,9097. Nilai AUC tersebut termasuk dalam kategori *excellent* ($AUC > 0,90$), yang menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam membedakan individu dengan pendapatan $\leq 50K$ dan $> 50K$. Kurva ROC yang berada jauh di atas garis diagonal juga menunjukkan bahwa model memiliki kemampuan diskriminasi yang tinggi dalam proses klasifikasi.

4.3 Interpretasi Model

4.3.1 Feature Importance

Untuk mengetahui fitur yang paling berpengaruh terhadap hasil prediksi, dilakukan analisis feature importance pada model XGBoost. Lima fitur dengan nilai importance tertinggi ditampilkan pada Tabel 4.6.

Tabel 4.6 *Feature Importance* Model XGBoost


Peringkat	Fitur	Importance	Interpretasi
1	relationship	0,3171	Status hubungan dalam keluarga berkaitan dengan peran ekonomi individu.
2	education.num	0,110	Tingkat pendidikan yang lebih tinggi cenderung berkaitan dengan peluang memperoleh pendapatan yang lebih tinggi
3	marital.status	0,094	Status pernikahan memberikan kontribusi yang cukup besar dalam membedakankategori pendapatan.
4	capital.gain	0,1408	Keuntungan modal menjadi indikator kuat kelompok berpendapatan tinggi.
5	hours.per.week	0,056	Jumlah jam kerja per minggu turut memengaruhi prediksi pendapatan, meskipun kontribusinya lebih kecil dibanding empat fitur teratas.

Berdasarkan Tabel 4.6, fitur *relationship* menjadi fitur paling penting dengan nilai importance sebesar 0,445. Hal ini menunjukkan bahwa status hubungan dalam keluarga memiliki kontribusi terbesar terhadap prediksi pendapatan. Fitur *education.num* menempati posisi kedua dengan nilai importance sebesar 0,110, yang menunjukkan bahwa tingkat pendidikan berpengaruh terhadap peluang memperoleh pendapatan yang lebih

tinggi. Selanjutnya, fitur *marital.status* memiliki nilai importance sebesar 0,094, menandakan bahwa status pernikahan juga berkontribusi dalam membedakan kategori pendapatan. Fitur *capital.gain* berada pada urutan keempat dengan nilai importance sebesar 0,088, sedangkan *hours.per.week* menempati urutan kelima dengan nilai importance sebesar 0,056, yang menunjukkan bahwa jumlah jam kerja per minggu turut memengaruhi hasil prediksi meskipun kontribusinya lebih kecil dibandingkan fitur-fitur sebelumnya.

4.3.2 Interpretasi SHAP

Analisis SHAP (SHapley Additive exPlanations) digunakan untuk memperkuat interpretasi model karena mampu menjelaskan besar dan arah kontribusi setiap fitur terhadap prediksi secara individual, tidak hanya secara global. Hasil SHAP summary plot ditampilkan pada Gambar 4.5 berikut ini.



Gambar 4.3 SHAP Summary Plot (Beeswarm)

Gambar 4.3 menampilkan SHAP Summary Plot yang memvisualisasikan distribusi nilai SHAP untuk setiap fitur pada model XGBoost. Setiap titik merepresentasikan satu observasi, dengan warna merah menunjukkan nilai fitur yang tinggi dan warna biru menunjukkan nilai fitur yang rendah. Posisi titik pada sumbu horizontal menunjukkan arah dan besarnya kontribusi fitur terhadap hasil prediksi model. Berdasarkan gambar tersebut, fitur *age* memiliki pengaruh paling besar terhadap prediksi model, diikuti oleh *relationship*, *marital.status*, *education.num*, dan *capital.gain*.

Selain itu, nilai *capital.gain* yang tinggi cenderung memberikan kontribusi positif terhadap prediksi kelas pendapatan >50K, sedangkan nilai *education.num* yang lebih tinggi juga meningkatkan kecenderungan model untuk memprediksi kelas tersebut. Secara keseluruhan, hasil SHAP menunjukkan bahwa faktor usia, status hubungan keluarga,

status pernikahan, tingkat pendidikan, dan keuntungan modal merupakan fitur-fitur yang paling berpengaruh dalam proses klasifikasi pendapatan oleh model XGBoost.

4.4 Pembahasan

4.4.1 Pembahasan Performa Model

Hasil evaluasi menunjukkan bahwa model ensemble berbasis pohon memiliki performa lebih baik dibandingkan model linear. Logistic Regression memperoleh accuracy 0,7698 dengan F1-Score kelas 1 hanya 0,61, menunjukkan ketidakmampuan model linear dalam menangkap pola non-linear pada dataset Adult Census Income. Random Forest meningkat signifikan dengan accuracy 0,8364 dan F1-Score 0,67, sedangkan XGBoost mencapai performa tertinggi dengan accuracy 0,8522, F1-Score kelas 1 sebesar 0,70, dan AUC 0,910.

XGBoost menjadi model terbaik karena mekanisme boosting yang memperbaiki kesalahan prediksi secara iteratif, dilengkapi regularisasi L1/L2 bawaan yang mencegah overfitting. Perbandingan komprehensif seluruh model termasuk hasil tuning disajikan pada Tabel 4.7.

Tabel 4.7 Ringkasan Perbandingan Seluruh Model


Model	Accuracy	Precision (>50K)	Recall (>50K)	F1 (>50K)	AUC
Logistic Regression	0,7698	0,52	0,76	0,61	0,849
Random Forest	0,8364	0,65	0,70	0,67	0,892
XGBoost Default (Model Final)	0,8522	0,68	0,73	0,70	0,910
Tuned XGBoost (F1-scoring)	0,8351	0,63	0,79	0,70*	0,905

F1-Score Tuned XGBoost = 0,6965, lebih rendah dari XGBoost Default (0,7042), sehingga XGBoost Default ditetapkan sebagai model final.

4.4.2 Analisis Overfitting dan Underfitting

Untuk mendiagnosis kondisi model, dilakukan analisis learning curve pada model XGBoost Default. Learning curve memplot Training Score dan Validation Score (5-fold

cross-validation) sebagai fungsi dari jumlah data training yang digunakan. Hasil learning curve ditampilkan pada Gambar 4.6.



Gambar 4.4 *Learning Curve* Model XGBoost Default

Gambar 4.6 menampilkan learning curve XGBoost Default dengan data training setelah SMOTE (total 39.516 observasi). Ringkasan nilai training score dan validation score pada setiap ukuran data disajikan pada Tabel 4.8.

Tabel 4.8 Ringkasan *Learning Curve* XGBoost Default

Jumlah Data Training	Training Score	Validation Score	Gap
3.951	0,9836	0,8496	0,1340
7.903	0,9629	0,8666	0,0964
11.855	0,9531	0,8711	0,0819
15.806	0,9453	0,8746	0,0707
19.758	0,9409	0,8780	0,0629
23.710	0,9362	0,8810	0,0552
27.661	0,9340	0,8807	0,0533
31.613	0,9311	0,8834	0,0476
35.564	0,9300	0,8825	0,0475
39.516	0,9280	0,8855	0,0425

Berdasarkan Tabel 4.8 dan Gambar 4.6, terdapat beberapa temuan penting. Pertama, training score dimulai sangat tinggi (0,9836) saat data sedikit, kemudian turun bertahap dan stabil di sekitar 0,9280 pada seluruh data training. Penurunan ini normal karena model tidak lagi sekadar menghafal data kecil. Kedua, validation score dimulai dari 0,8496 dan naik konsisten hingga 0,8855 dengan variasi yang semakin mengecil, menunjukkan model semakin baik dalam generalisasi seiring penambahan data.

Ketiga, gap antara training score dan validation score mengecil secara signifikan dari 0,1340 (data sedikit) menjadi 0,0425 (seluruh data training). Gap akhir sebesar 0,0425 berada dalam batas wajar dan menunjukkan konvergensi yang baik. Berdasarkan kriteria diagnostik (gap akhir $< 0,05$ dan kedua kurva konvergen ke nilai tinggi), model XGBoost Default dinyatakan berada pada kondisi Good Fit. model telah mencapai keseimbangan bias-variance yang baik dan mampu melakukan generalisasi dengan baik pada data baru.

Sebagai perbandingan, Logistic Regression menunjukkan indikasi underfitting karena performanya konsisten lebih rendah pada seluruh metrik. Keterbatasan fundamental Logistic Regression sebagai model linear membuatnya tidak mampu menangkap relasi non-linear antar fitur pada dataset ini.

4.4.3 Pembahasan Penanganan Class Imbalance

Data asli memiliki ketidakseimbangan kelas yang signifikan: kelas $\leq 50K$ berjumlah 75,91% dan kelas $> 50K$ hanya 24,09%. Pada penelitian ini, SMOTE diterapkan dengan prosedur yang tepat hanya pada data latih setelah train-test split. Prosedur ini penting untuk menghindari data leakage yang terjadi jika SMOTE diterapkan sebelum split, di mana sampel sintesis akan tersebar ke test set sehingga evaluasi menjadi bias dan terlalu optimis.

Setelah SMOTE diterapkan pada data latih, distribusi kelas menjadi seimbang dengan masing-masing kelas berjumlah 19.758 observasi (total 39.516). Data uji tetap mempertahankan distribusi aslinya (4.940 kelas $\leq 50K$ dan 1.568 kelas $> 50K$) agar evaluasi mencerminkan kondisi data populasi nyata. Hasil recall kelas 1 sebesar 0,7302 pada model final menunjukkan SMOTE efektif membantu model mengenali kelas minoritas, meskipun masih terdapat trade-off dengan precision kelas 1 (0,68) yang mencerminkan adanya false positive yang wajar.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat diperoleh beberapa kesimpulan sebagai berikut.

1. Karakteristik yang paling berpengaruh terhadap tingkat pendapatan berdasarkan hasil Feature Importance dan SHAP adalah relationship, education.num, marital.status, capital.gain, serta hours.per.week. Fitur-fitur tersebut memberikan kontribusi terbesar dalam membedakan individu dengan pendapatan $\leq 50K$ dan $> 50K$.
2. Tahap preprocessing berhasil mempersiapkan data sebelum pemodelan dengan melakukan penanganan missing value menggunakan imputasi modus, menghapus data duplikat, mempertahankan outlier yang masih merepresentasikan kondisi nyata, melakukan label encoding pada variabel kategorikal, serta standardisasi pada fitur numerik sehingga data siap digunakan tanpa menyebabkan *data leakage*.
3. Feature engineering dan penanganan class imbalance dilakukan menggunakan SMOTE yang diterapkan hanya pada data latih setelah proses *train-test split*. Pendekatan ini berhasil menyeimbangkan distribusi kelas sehingga model mampu mengenali kelas minoritas ($> 50K$) dengan lebih baik tanpa menyebabkan kebocoran data.
4. Model terbaik pada penelitian ini adalah XGBoost Default, dengan nilai Accuracy sebesar 85,22%, Precision kelas $> 50K$ sebesar 0,68, Recall sebesar 0,73, F1-Score sebesar 0,70, dan ROC-AUC sebesar 0,9097. Hasil tersebut menunjukkan bahwa XGBoost memiliki kemampuan klasifikasi yang sangat baik dibandingkan Logistic Regression dan Random Forest pada dataset Adult Census Income.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dijadikan bahan pertimbangan untuk penelitian maupun pengembangan lebih lanjut, yaitu sebagai berikut.

1. Penelitian selanjutnya dapat membandingkan performa XGBoost dengan algoritma lain, seperti LightGBM, CatBoost, atau Artificial Neural Network (ANN) untuk memperoleh model dengan kinerja yang lebih optimal.
2. Proses optimasi model dapat dikembangkan menggunakan metode *hyperparameter tuning* yang lebih komprehensif, seperti Bayesian Optimization atau Optuna, sehingga diperoleh kombinasi parameter yang lebih optimal.

3. Penelitian selanjutnya dapat menggunakan dataset yang lebih besar, lebih mutakhir, atau menambahkan variabel lain yang berkaitan dengan kondisi sosial, ekonomi, maupun pekerjaan agar model memiliki kemampuan generalisasi yang lebih baik.
4. Model yang dihasilkan dapat dikembangkan menjadi sistem pendukung keputusan atau aplikasi prediksi tingkat pendapatan sehingga dapat dimanfaatkan sebagai alat bantu analisis dalam berbagai bidang, seperti penelitian, pendidikan, maupun pengambilan kebijakan berbasis data.

LAMPIRAN

Lampiran 1. Source Code Google Colab

Berisi seluruh kode program yang digunakan pada penelitian:

<https://colab.research.google.com/drive/1grIjqBaBhq3r6T1F-8GJoIRU1lFjmrKl?usp=sharing>

Lampiran 2. Repository GitHub

Repository GitHub yang memuat source code penelitian dapat diakses melalui tautan berikut:

<https://github.com/Fatihaturrohman/Project-Machine-Learning-kelompok-A>

Lampiran 3. Link AI

Berisi dokumentasi percakapan dengan Artificial Intelligence (AI) yang digunakan sebagai pendukung dalam proses penyusunan, analisis, dan pengembangan penelitian. Dokumentasi dapat diakses melalui tautan berikut:

<https://chatgpt.com/share/6a3b9f51-be90-83ec-b7cf-4d810e3flab0>

